

Electio-Analytics

Dossier de Synthèse

Prédiction des élections municipales 2026

Département de l'Hérault (34), 341 communes

MSPR BLOC 3 : Pilotage des systèmes d'information décisionnels
Big Data et Business Intelligence

Juin 2025

341

communes analysées

12

sources de données

89,6 %

précision test 2020

Axel POIDEBARD Michael PICARD Cédric SANCHEZ
Mamadou Alpha DIALLO Léa GUECHOUM

Table des matières

Résumé exécutif	3
1 Introduction	3
2 Gestion de projet	3
2.1 Organisation et outils	3
2.2 Workflow Gitflow	3
2.3 Conventional commits	4
3 Périmètre et justification	4
3.1 Choix du département de l'Hérault (34)	4
3.2 Période couverte	5
4 Données et sources	5
4.1 Sources mobilisées	5
4.2 Modèle conceptuel de données (MCD)	5
5 Pipeline ETL	5
5.1 Architecture générale	5
5.2 Étapes de traitement	5
5.3 Points techniques clés	7
6 Analyse exploratoire	7
6.1 Tendance électorale départementale (2008–2020)	7
6.2 Répartition géographique du vote en 2020	7
6.3 Corrélations entre indicateurs socio-économiques et vote	8
7 Modèle prédictif	8
7.1 Méthodologie	8
7.2 Résultats et performance	10
8 Prédictions 2026	12
8.1 Extrapolation des indicateurs	12
8.2 Résultats	12
9 Restitution : Dashboard Metabase	12
9.1 Lancement de l'instance	13
9.2 Connexion à l'ETL	13
10 MLOps : orchestration du pipeline avec ZenML	13
10.1 Architecture du pipeline ZenML	15
10.2 Stockage des artefacts avec MinIO	15
11 RGPD et sécurité des données	16
11.1 Qualification des données traitées	16
11.2 Privacy by design et mesures de sécurité	16
12 Limites et perspectives	16
12.1 Limites méthodologiques	16
12.2 Perspectives d'amélioration	16
Conclusion	17

Annexes	17
A Visualisations complémentaires	17

Résumé exécutif

Ce dossier présente les travaux réalisés dans le cadre de la MSPR Pilotage des systèmes d'information décisionnels, commandée par le client fictif Electio-Analytics. L'objectif est de pouvoir prédire avec précision le résultat des élections municipales 2026 pour les 341 communes du département de l'Hérault (34), à partir de données socio-économiques publiques (INSEE, data.gouv.fr, DGFIP).

Un pipeline ETL traitant 12 jeux de données bruts (3,5 GB) et les centralise dans une base SQLite de 12 tables. Un modèle Random Forest, entraîné sur les données propres aux élections de 2008 et 2014, atteint **89,6 %** de précision sur le test 2020 ($F1 = 0,906$). Pour 2026, le modèle prédit une domination de la droite dans l'Hérault, avec tout de même une remontée de la gauche principalement au niveau de la métropole de Montpellier (13,9 % en 2020 contre 21,6 % prédit).

1 Introduction

Electio-Analytics est une société de conseil stratégique fondée en 2017, spécialisée dans l'analyse de données électorales. Notre expertise nous permet efficacement d'accompagner des entités politique lors de leurs campagnes, leur apportant des conseils stratégique considérable pour ensuite pouvoir prendre des décisions éclairées sur le déploiement des ressources et des efforts.

Ce projet s'inscrit dans le cadre du MSPR BLOC 3 (certification RNCP35584 : Expert en Informatique et Système d'Information). La mission couvre six livrables :

- la définition et la justification d'un périmètre géographique ;
- la collecte et l'intégration de données publiques historiques ;
- un pipeline ETL reproductible vers une base normalisée ;
- une analyse exploratoire des corrélations socio-économiques et électorales ;
- un modèle prédictif supervisé, entraîné et validé ;
- des prédictions pour les municipales 2026, interprétables par un client non technique.

2 Gestion de projet

2.1 Organisation et outils

La gestion du projet et du versionnage de nos codes reposent sur deux outils principaux. Nous avons utilisé **Jira** pour le suivi des tickets et l'organisation des sprints, permettant de prioriser les fonctionnalités et de suivre l'avancement. **GitHub** centralise le code source, les review (pull requests) et l'historique complet des modifications.

2.2 Workflow Gitflow

Le dépôt suit le workflow **Gitflow**, structuré autour de deux branches pérennes et de branches éphémères :

- **main** : branche de production, protégée, mise à jour uniquement lors des releases depuis **develop** ;
- **develop** : branche d'intégration continue, recevant les fusions des branches de fonctionnalité après revue de code ;
- **feature/xxx** : branches éphémères créées depuis **develop**, fusionnées via pull request.

(cf fig. 1)




Figure 1 – Workflow Gitflow : branches `main`, `develop` et branches de fonctionnalité, fusion par pull request

2.3 Conventional commits

Chaque commit respecte la spécification *Conventional Commits*, qui structure le message selon le format `type(scope): description`. Cette convention facilite la compréhension générale de l'équipe aux développements d'autre membre, et nous permet de suivre efficacement les changements.

Table 1 – Types de commits utilisés sur le projet

Type	Usage
feat	Nouvelle fonctionnalité
fix	Correction de bug
refactor	Refactoring sans changement de comportement
docs	Documentation uniquement
test	Ajout ou modification de tests
chore	Maintenance, dépendances, configuration

Exemples de commits produits pendant le projet :

- feat(etl): add streaming reader for 2.3GB election file
- feat(model): implement Random Forest with temporal split
- fix(etl): fix codgeo normalization for DGFIP multi-column format
- feat(dashboard): configure Metabase Docker Compose stack
- docs(readme): add compilation and ETL run instructions

3 Périmètre et justification

3.1 Choix du département de l'Hérault (34)

Le périmètre retenu est le département de l'Hérault (code INSEE 34), soit **341 communes**. Ce choix répond à quatre critères complémentaires.

Diversité politique. Montpellier vote majoritairement à gauche ; Béziers est gouvernée par le Rassemblement National depuis 2014 ; les communes rurales de l'arrière-pays présentent des profils hétérogènes. Cette diversité offre au modèle un corpus de données riche, indispensable pour entraîner un modèle généralisable.

Diversité territoriale. La coexistence d'une grande ville étudiante, de villes côtières (Sète, Agde), de zones périurbaines et d'un arrière-pays rural couvre un éventail de catégories socioprofessionnelles très complet, d'autant plus de nuance que le modèle doit être capable de distinguer.

Impact environnemental. L'Hérault est régulièrement exposé aux inondations et à la sécheresse méditerranéenne. Les données de catastrophes naturelles (GASPAR) constituent un

indicateur discriminant propre à ce territoire.

Volume exploitable. Avec 341 communes et 3 élections municipales, on obtient environ 690 observations : suffisant pour un apprentissage supervisé sans recourir à des techniques d’augmentation de données.

3.2 Période couverte

Les élections municipales de 2008, 2014 et 2020. Nos données sur les indicateurs socio-économiques s’étendent de 1876 (population historique) à 2024 (état civil), offrant une lecture robuste des dynamiques territoriales, même étendues dans le temps.

4 Données et sources

4.1 Sources mobilisées

Nous avons collectés 12 jeux de données publique issus de source gouvernementale. Le tableau 2 présente une vue d’ensemble de ces jeux de données.

Table 2 – Sources de données mobilisées

Thématique	Source	Contenu	Période
Élections	data.gouv.fr	Résultats municipaux par bureau de vote (2,3 GB)	1999–2024
Economie	data.gouv.fr	Revenus médians par commune	2000–2022
	INSEE	CSP des actifs 25–54 ans (9 années de recensement)	1968–2022
	INSEE	Secteurs d’activité par sexe	1968–2022
	DGFiP	Comptes individuels des communes (4 fichiers, 650 MB)	2000–2022
Education	INSEE	Diplômes et formation, recensement 2022 (81 MB)	2022
	INSEE	Croisement CSP x diplôme (8 années de recensement)	1968–2022
Demographie	INSEE	Population historique (39 recensements)	1876–2023
	INSEE	Naissances par commune	2008–2024
	INSEE	Décès par commune	2008–2024
Environnement	data.gouv.fr	Arrêtés CatNat GASPARE (260 799 arrêtés)	1985–2022
	data.gouv.fr	Inventaire des risques GASPARE (172 595 entrees)	–

4.2 Modèle conceptuel de données (MCD)

La base SQLite `electio_herault.db` centralise l’ensemble de ces sources en **12 tables**, toutes reliées à la table centrale `communes` via la clé primaire `codegeo` (code INSEE commune à 5 chiffres). (cf fig. 2)

5 Pipeline ETL

5.1 Architecture générale

Le pipeline est implémenté dans `scripts/etl/etl_pipeline.py` et s’exécute via `python main.py etl`. Il reconstruit intégralement la base à chaque exécution, garantissant une reproductibilité totale. (cf fig. 3)

5.2 Étapes de traitement

Le tableau 3 détaille les 12 étapes séquentielles du pipeline.




Figure 2 – Modèle conceptuel de données : 12 tables reliées à **communes** par codegeo (FK)




Figure 3 – Architecture du pipeline ETL

Table 3 – Étapes du pipeline ETL

N	Table	Traitement principal
1	communes	Référentiel des 341 communes du Hérault (source : population historique)
2	élections	Lecture streaming 2,3 GB ; filtre municipales + dept 34 ; classification Gauche/Droite
3	population	Pivot de 39 colonnes PMUN/PSDC en lignes (codegeo, année, population)
4	naissances_deces	Jointure bulletins naissances et décès sur (codegeo, année)
5	revenus	Détection automatique du séparateur, nettoyage des colonnes
6	csp	Lecture des 9 onglets Excel COM_xxxx (1968–2022), concaténation
7	secteurs_activite	Même logique que csp, répartition par secteur et par sexe
8	diplômes	Détection automatique de l'encodage (utf-8/latin-1), 81 MB
9	csp_diplome	Croisement de 6 CSP et 6 niveaux de diplôme sur 8 années
10	comptes_communes	Fusion de 4 fichiers DGFIP, extraction des 12 colonnes financières clés
11	catnat	Filtre dept 34, extraction du type de risque et des dates d'arrêt
12	risques	Inventaire des risques naturels et technologiques par commune

5.3 Points techniques clés

Lecture streaming (2,3 GB). Le fichier des résultats électoraux dépasse la mémoire disponible. Il est parcouru ligne par ligne avec `csv.reader` : les 30 millions de lignes nationales sont filtrées à la volée, réduisant le volume à quelques dizaines de milliers de lignes pour le seul département 34.

Normalisation des codes INSEE. Toutes les jointures reposent sur un `codegeo` à 5 caractères (ex. : 34172 pour Montpellier). Selon la source, ce code peut être fourni en une ou deux colonnes, avec ou sans zéros de tête. Le pipeline normalisé systématiquement avec `dep.zfill(2)` + `commune.zfill(3)` pour les fichiers DGFIP, et `str.zfill(5)` pour les autres sources.

Classification Gauche / Droite. Chaque résultat électoral est enrichi d'une colonne `camp`. La classification s'appuie en priorité sur le code de nuance officiel du ministère de l'Intérieur (plus de 80 nuances référencées), puis sur des mots-clés dans le libellé de liste. Les listes LREM/ENS/Renaissance sont classées à droite ; les listes sans nuance identifiable sont classées Droite par défaut.

6 Analyse exploratoire

6.1 Tendence électorale départementale (2008–2020)




Figure 4 — Évolution du vote Gauche/Droite aux élections municipales T1, Hérault (34), 2008–2020

La figure 4 retrace l'évolution du vote municipal dans l'Hérault sur trois scrutins. La tendance est nette : le camp de gauche recule de 41,5 % en 2008 à 13,9 % en 2020. Ce mouvement traduit à la fois un recul structurel dans les communes rurales et périurbaines, et une fragmentation de l'offre progressiste qui dilue les voix entre plusieurs listes.

6.2 Répartition géographique du vote en 2020

La carte (figure 5) confirme la concentration spatiale du vote de gauche autour de Montpellier et de sa première couronne. Le reste du département vote majoritairement à droite, avec une présence marquée du Rassemblement National dans le Bezérois. Cette concentration est un enjeu clé pour le modèle : les seules 22 communes de gauche sur 341 créent un fort déséquilibre de classes.




Figure 5 – Vote Gauche/Droite par commune, municipales T1 2020, Hérault (bleu : Gauche, rouge : Droite)

6.3 Corrélations entre indicateurs socio-économiques et vote

La heatmap (figure 6) synthétise les relations entre les indicateurs retenus et le vote Gauche. Les enseignements principaux sont les suivants.

- **CatNat ($r = 0,40$)** : la corrélation la plus forte, mais largement due à un biais de taille : les grandes villes cumulent plus d'arrêtés et votent davantage à gauche. Ce lien n'est pas directement causal.
- **Cadres ($r = 0,13$)** : légère tendance des communes à fort taux de cadres vers la gauche, reflétant le profil des villes universitaires et tertiaires.
- **Revenu médian, diplômes, ouvriers ($r < 0,10$)** : corrélations quasi nulles, à contre-courant des intuitions classiques sur le « vote de classe ».

Ces résultats motivent le recours à un modèle non linéaire capable de combiner des signaux faibles. Les visualisations complémentaires (scatter plots individuels, boîtes à moustaches, évolution démographique) sont disponibles en annexe A.

7 Modèle prédictif

7.1 Méthodologie

L'algorithme retenu est **Random Forest** (scikit-learn, Python), utilisé en double mode : classification binaire Gauche/Droite et régression du pourcentage de vote Gauche.

Construction du tableau d'entraînement. Chaque observation correspond à une commune lors d'une élection (commune x année d'élection). En croisant les 341 communes et les 3 scrutins disponibles, on obtient environ **690 observations**. Pour chaque observation, les indicateurs socio-économiques les plus proches de l'année cible sont joints. Cette approche diachronique permet au modèle d'apprendre non seulement des corrélations statiques, mais aussi des dynamiques territoriales (ex. : une commune dont la part de cadres augmente tend à glisser vers la gauche).

Features retenues (13 variables). Population, part de cadres, d'ouvriers, d'employés et de professions intermédiaires, revenu médian, part de diplômes supérieurs et sans diplôme, dette par habitant, investissement par habitant, taux de natalité, nombre d'arrêtés CatNat.




Figure 6 – Matrice de corrélation entre indicateurs socio-économiques et vote, Hérault (34), municipales 2020

Validation temporelle. Entraînement sur 2008 et 2014, évaluation sur 2020. Ce « split temporel » est plus exigeant qu’une validation croisée classique : il simule une véritable prédiction sur un scrutin futur, sans fuite d’information.

7.2 Résultats et performance




Figure 7 – Importance des variables selon le Random Forest, classification Gauche/Droite, Hérault (34)

La figure 7 montre que trois variables dominent la classification : la population (0,175), la dette par habitant (0,135) et l’investissement par habitant (0,125). Les variables de CSP, diplôme et revenu contribuent de façon plus équilibrée (0,06 à 0,07 chacune). Ce résultat confirme qu’aucun facteur seul ne suffit : le modèle exploite la combinaison de multiples signaux faibles.

La matrice de confusion (figure 8) indique que le modèle classe correctement 274 des 296 communes de droite, mais seulement 11 des 22 communes de gauche. Cette asymétrie s’explique par le déséquilibre des classes : avec 22 communes de gauche sur 341, le modèle tend naturellement vers la majorité. Le tableau 4 résume les métriques globales.

Table 4 – Métriques de performance du modèle (test 2020)

Métrique	Valeur
Accuracy	89,6 %
F1-score (pondéré)	0,906
Droite : communes correctes / total	274 / 296
Gauche : communes correctes / total	11 / 22
R ² régression (% Gauche)	−0,546
MAE régression	17,8 points

La régression du pourcentage de vote Gauche est peu fiable (R² négatif) : le modèle converge vers la moyenne et peine sur les valeurs intermédiaires. Les prédictions 2026 s’appuient donc




Figure 8 – Matrice de confusion, Random Forest, test 2020 (accuracy = 89,6 %, F1 = 0,906)

principalement sur la **classification binaire**, plus robuste.

8 Prédictions 2026

8.1 Extrapolation des indicateurs

Pour produire des prédictions 2026, le modèle nécessite des valeurs d'indicateurs futures, non encore disponibles. On procède à une extrapolation conservatrice :

- **Population** : la tendance linéaire observée sur 2014–2020 est prolongée pour chaque commune individuellement.
- **Tous les autres indicateurs** : les valeurs 2020 sont maintenues (hypothèse de stabilité socio-économique à court terme).

Cette hypothèse est une limite méthodologique explicitement assumée (voir section 12).

8.2 Résultats




Figure 9 — Prédiction du vote Gauche par commune, municipales 2026, Hérault (34) (bleu : Gauche, rouge : Droite)

La carte (figure 9) confirme la domination de la droite sur l'ensemble du territoire héraultais en 2026. Les zones bleues se limitent à Montpellier et à quelques communes de la première couronne. Le modèle prédit une progression de la gauche : 13,9 % de communes en 2020 contre 21,6 % prédit en 2026 (+7,7 points). Cette remontée est davantage attribuable au mécanisme de régression vers la moyenne propre au Random Forest qu'à un signal politique fort.

Le tableau 5 détaille les prédictions pour les communes politiquement significatives.

9 Restitution : Dashboard Metabase

Metabase est un outil de Business Intelligence open source qui permet de créer des dashboards interactifs à partir d'une base de données, sans écrire de code front-end. Dans ce projet, il sert d'interface de visualisation pour les résultats du pipeline ETL et du modèle prédictif. Trois dashboards sont configurés : Dashboard 1 (Prédictions 2026), Dashboard 2 (Validation du modèle) et Dashboard 3 (Profil socio-démographique).

Table 5 – Prédictions 2026 pour les communes remarquables

Commune	Résultat 2020	Prédiction 2026	Tendance
Montpellier	61,7 % Gauche	37–39 %	Maintien à gauche, legere baisse
Lunel	>50 % Gauche	>50 %	Reste à gauche
Béziers	11 % Gauche	~39 %	Remontée, compétition accrue
Agde	9 % Gauche	~31 %	Remontée significative
Sète	~37 % Gauche	~37 %	Stable, pas de basculement

9.1 Lancement de l'instance

Metabase tourne via Docker Compose avec deux services (`docker compose up -d`) :

Table 6 – Services Docker Compose

Service	URL	Rôle
electio_metabase	http://localhost:3000	Interface Metabase
electio_images	http://localhost:8080	Serveur de fichiers statiques (PNGs matplotlib)

La base SQLite est montée dans le conteneur via un volume Docker (`./data/output:sqlite-data`). La connexion est configurée dans Metabase sous *Admin* → *Bases de données*, chemin `/sqlite-data/electio_herault.db`.

9.2 Connexion à l'ETL

Le pipeline complet suit cet ordre :

1. `python main.py etl` reconstruit la base SQLite (12 tables) ;
2. `python main.py predict` entraîne le modèle et écrit les résultats en base ;
3. `docker compose restart metabase` force Metabase à relire le schéma. Ce redémarrage est obligatoire après chaque ETL : Metabase met en cache le schéma et ne détecte pas automatiquement les changements.

Les cinq tables écrites par `main.py predict` et consommées par Metabase sont les suivantes :

Table 7 – Tables du modèle exposées dans Metabase

Table	Contenu
feature_importances	Importance de chaque variable selon le Random Forest
metriques_modele	Accuracy, F1, R^2 , MAE
predictions_test_2020	Prédictions sur le jeu de test avec écarts et flag correct/incorrect
predictions_2026	Prédictions pour les municipales 2026 par commune
comparaison_2020_2026	Bascules de camp entre 2020 et 2026

Le Dashboard 1, présenté figure 10, offre une vue synthétique des prédictions 2026 : carte par commune, tableau des bascules de camp, et indicateurs clés de performance du modèle. Les dashboards complémentaires (validation du modèle et analyse socio-démographique) sont reproduits en annexe A.

10 MLOps : orchestration du pipeline avec ZenML

Le pipeline de données et de modélisation est orchestré via **ZenML**, un framework MLOps open source qui transforme des fonctions Python ordinaires en étapes traçables, versionnées et reproductibles. Chaque exécution du pipeline est enregistrée avec ses métadonnées, ses artefacts de sortie et ses logs, garantissant une traçabilité complète de la chaîne de traitement.




Figure 10 — Dashboard Metabase : Prédictions 2026 par commune, Hérault (34)

10.1 Architecture du pipeline ZenML

Le pipeline `electio_analytics_pipeline` enchaîne quatre étapes séquentielles, visibles dans l'interface ZenML (figure 11) :

1. **download_data** : téléchargement et vérification des sources brutes ; produit un dictionnaire de chemins de fichiers (`dict`) ;
2. **run_etl** : exécution du pipeline ETL complet, normalisation des codes INSEE, classification Gauche/Droite ; produit le `DataFrame` consolidé des 341 communes sur trois scrutins ;
3. **train_model** : entraînement du Random Forest sur les scrutins 2008 et 2014, sérialisation du modèle ; produit un dictionnaire de métriques et l'artefact modèle (`dict`) ;
4. **evaluate_model** : évaluation sur le jeu de test 2020, génération du rapport de performance ; produit un rapport au format `HTMLString`, consultable directement dans l'interface ZenML.




Figure 11 – Interface ZenML : exécution #0001-electio_analytics_pipeline, 4 étapes complétées, rapport d'évaluation en sortie `HTMLString`

10.2 Stockage des artefacts avec MinIO

Les artefacts produits à chaque étape (données transformées, modèle entraîné, rapport HTML) sont persistés dans un bucket **MinIO**, solution de stockage objet compatible S3 déployée localement. ZenML est configuré pour utiliser ce bucket comme *artifact store* : chaque artefact est versionné automatiquement et accessible depuis l'interface ZenML ou via le SDK Python.

Cette architecture présente plusieurs avantages pour le projet :

- **Reproductibilité** : chaque run produit des artefacts immuables, identifiés par un UUID, permettant de rejouer ou comparer des exécutions antérieures ;
- **Découplage** : le pipeline peut être relancé partiellement depuis n'importe quelle étape en réutilisant les artefacts déjà calculés ;
- **Observabilité** : les logs, métriques et sorties HTML sont accessibles centralement sans avoir à relancer le pipeline.

11 RGPD et sécurité des données

Le POC mobilise exclusivement des données publiques en open data (INSEE, data.gouv.fr, DGFIP, GASPAR), traitées en local sur une base SQLite régénérée à chaque exécution. Cette section synthétise la qualification RGPD et les mesures de sécurité retenues.

11.1 Qualification des données traitées

Les indicateurs socio-économiques (INSEE), démographiques, financiers (DGFIP) et environnementaux (GASPAR) sont des agrégats communaux soumis au secret statistique (seuil INSEE de 11 ménages) : ils sont hors champ du RGPD. La seule donnée à caractère personnel présente est l'identité des candidats (table `elections`), publiée légalement au Journal officiel. Son traitement repose sur la base légale de l'article 6.1.e du RGPD (mission d'intérêt public) et reste proportionné à la finalité d'analyse électorale agrégée. Aucune donnée sensible au sens de l'article 9 n'est traitée, aucun scoring individuel n'est produit. Toutes les sources sont diffusées sous Licence Ouverte Étalab 2.0, qui autorise la réutilisation (y compris commerciale) sous réserve de citation de la source.

11.2 Privacy by design et mesures de sécurité

Les principes de *privacy by design* sont appliqués dès la conception : minimisation (seules les colonnes utiles sont conservées en sortie d'ETL), limitation de finalité (usage strictement électoral, aucun profilage individuel), limitation de conservation (la base SQLite est régénérée à chaque exécution, sans fichiers intermédiaires persistants), exactitude (pipeline reproductible avec contrôles de validation).

Côté sécurité technique, le POC fonctionne en environnement strictement local : base SQLite et dashboard Metabase déployés via Docker Compose, sans exposition réseau ni transfert cloud. Aucun secret n'est versionné, les données brutes (3,5 GB) sont exclues du dépôt Git via `.gitignore`, et le pipeline est tracé par Git avec `random_state` fixe pour la reproductibilité.

Compte tenu du périmètre du POC (mono-poste, pas de transmission tierce, pas de décision automatisée sur un individu), une AIPD, un registre des traitements article 30 et la désignation d'un DPO ne sont pas requis. Ces obligations devront être réinstanciées en cas de mise en production, notamment si le périmètre s'élargit à des sondages, des données de campagne ou tout signal individuel, auquel cas il faudra également prévoir un chiffrement au repos et en transit, une authentification forte sur le dashboard, et un hébergement souverain certifié.

12 Limites et perspectives

12.1 Limites méthodologiques

- **Hypothèse de stabilité.** Le modèle suppose que les relations entre indicateurs et vote restent constantes entre 2008 et 2026. Toute rupture structurelle invaliderait les prédictions.
- **Facteurs locaux non captés.** Popularité d'un maire sortant, scandales locaux, fermeture d'usine : ces éléments ponctuels peuvent faire basculer une commune sans que les indicateurs agrégés l'anticipent.
- **Extrapolation naïve.** Seule la population est extrapolée ; tous les autres indicateurs restent fixés à leur valeur 2020.
- **Classification binaire simplificatrice.** Le positionnement de LREM/Renaissance à droite est discutable selon les contextes locaux. L'absence de catégorie Centre introduit un biais systématique.

12.2 Perspectives d'amélioration

- Intégration des résultats des élections législatives et européennes 2022–2024 comme features supplémentaires.

- Modélisation de l'abstention comme variable d'ajustement.
- Passage à une classification multi-classes : Gauche, Centre, Droite, Extrême-droite.
- Équilibrage des classes via SMOTE pour améliorer la détection des communes de gauche.

Conclusion

Ce projet démontre la faisabilité d'une modélisation prédictive du vote municipal à partir de données socio-économiques publiques. Avec 89,6 % de précision sur un scrutin non vu, le modèle valide l'hypothèse que les structures territoriales et économiques d'une commune sont suffisamment prédictives du comportement électoral pour constituer un outil d'aide à la décision.

Le pipeline ETL reproductible et la base SQLite normalisée constituent une infrastructure pérenne, extensible à d'autres départements ou à d'autres types d'élections. Pour 2026, le modèle prédit une domination de la droite dans l'Hérault, tout même avec une nuance importante dans la métropole de Montpellier, qui obtiendrait un regain de la gauche. Ces prédictions constituent un point de départ actionnable pour le client, à affiner à mesure que de nouvelles données (recensement, élections intermédiaires) seront disponibles.

Annexes

A Visualisations complémentaires

Les figures suivantes complètent l'analyse du corps du rapport. Chacune est accompagnée de la légende issue de l'analyse exploratoire et prédictive.




Figure 12 — Revenu médian vs % vote Gauche par commune, Hérault (34). Corrélation quasi nulle ($r = 0.073$) : le revenu seul ne suffit pas à expliquer l'orientation du vote.




Figure 13 – Distribution des revenus médians selon le camp majoritaire, municipales T1 2020. Les distributions Gauche et Droite sont très similaires (écart moyen de 581 EUR).




Figure 14 – Taux de cadres vs taux d'ouvriers par commune, coloré par camp. Les communes de gauche se concentrent dans la zone médiane, sans opposition franche entre catégories socioprofessionnelles.




Figure 15 – Part de diplômes supérieurs vs % vote Gauche. Relation très faiblement positive ($r = 0,059$), non linéaire : le lien diplôme/gauche s’observe surtout dans les communes les plus formées.




Figure 16 – Dette par habitant vs % vote Gauche. Corrélation légère ($r = 0,102$) : les communes de gauche tendent à afficher une dette supérieure, reflet d’une politique d’investissement plus active.




Figure 17 — Top 20 communes par nombre d'arrêtés de catastrophe naturelle. La forte corrélation CatNat/vote gauche ($r = 0,40$) est principalement un artefact de la taille urbaine.




Figure 18 — Évolution de la population des communes héraultaises, 1968–2022 (communes ≥ 100 hab. en 1968). L'Hérault affiche l'une des plus fortes croissances démographiques de France, tirée par la couronne montpelliéraine.




Figure 19 — Réel vs prédit 2020 en régression du % Gauche. $R^2 = -0,546$, MAE=17,8 points : le modèle reproduit les cas extrêmes mais converge vers la moyenne pour les valeurs intermédiaires.




Figure 20 – Évolution du vote Gauche pour les communes remarquables, 2008–2026 (trait plein : réel, tirets : prédit). Trajectoires contrastées entre Montpellier (gauche stable) et Béziers (forte remontée prédite).




Figure 21 – Évolution et prédiction du vote Gauche, moyenne départementale, municipales T1 2026. Légère remontée prédite : 13,9 % en 2020 vers 21,6 % en 2026 (+7,7 points).




Figure 22 – Distribution des prédictions par commune, municipales 2026. Distribution bimodale : pic massif à 0 % pour les communes rurales sans candidat de gauche identifié, puis distribution étalée entre 20 et 70 %.

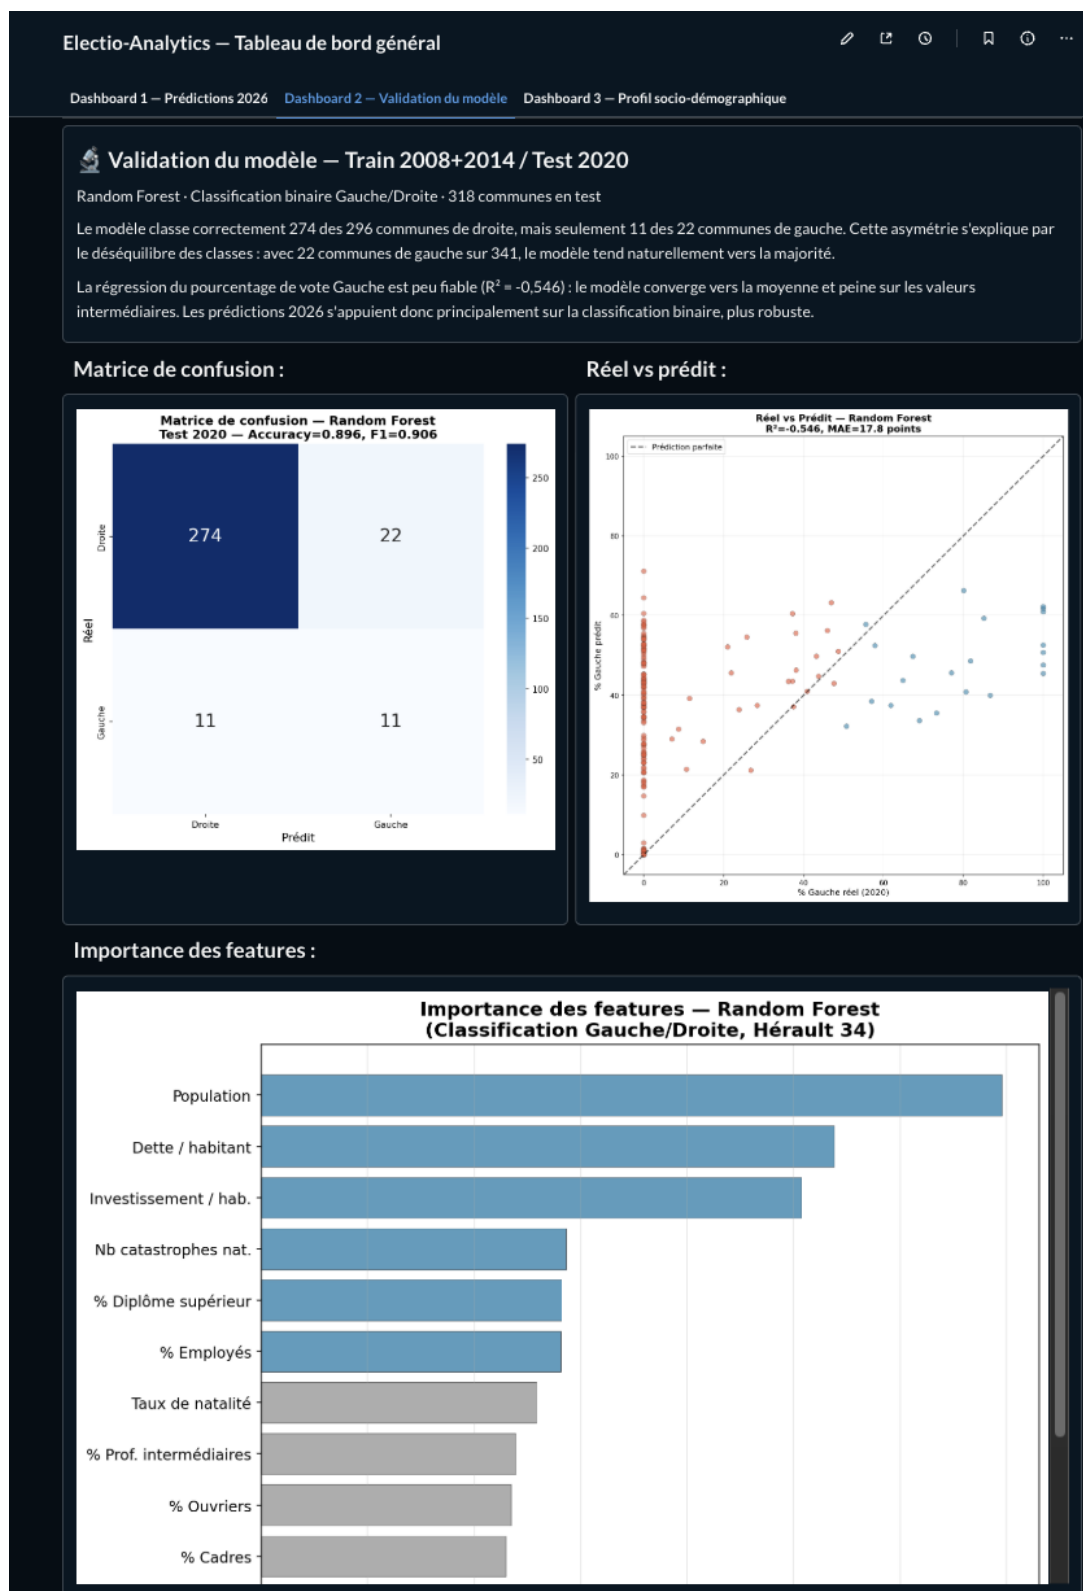


Figure 23 — Dashboard Metabase : Validation du modèle, prédictions test 2020, métriques de performance et importance des variables.




Figure 24 – Dashboard Metabase : Analyse socio-démographique, population, revenus, finances communales et démographie pour contextualiser les prédictions à l'échelle du territoire héraultais.